

0. 学习动机

方舱医院中为了改善cartographer定位会出现的跳变现象，使用IMU进行航迹推算，将它们的定位结果进行简单的融合，当cartographer定位和IMU推算的结果差距不大时，IMU使用cartographer的结果，重新开始航迹推算，如果差距过大，选择相信更加稳定的IMU结果，用IMU的结果在地图中进行重定位；

可以改善地图定位的跳变现象，但是当地图定位慢慢发生偏移的时候，由于设置阈值的关系，IMU会被地图定位带偏，所以，为了更好的对定位结果进行融合，需要使用滤波器的方法。

与此同时，为了实现新型的地面分割算法，也需要滤波器的知识，所以学习以卡尔曼滤波为代表的滤波方法。

学习方式为：

- 1.【网课】深蓝学院-多传感器融合定位-第四章；
- 2.【博客】

0.1 通俗理解卡尔曼滤波

0.1.1

假设你有两个传感器，测的是同一个信号。可是它们每次的读数都不太一样，怎么办？

取平均。

再假设你知道其中贵的那个传感器应该准一些，便宜的那个应该差一些。那有比取平均更好的办法吗？

加权平均。

怎么加权？假设两个传感器的误差都符合正态分布，假设你知道这两个正态分布的方差，用这两个方差值，（此处省略若干数学公式），你可以得到一个“最优”的权重。

接下来，重点来了：假设你只有一个传感器，但是你还有一个数学模型。模型可以帮你算出一个值，但也不是那么准。怎么办？

把模型算出来的值，和传感器测出的值，（就像两个传感器那样），取加权平均。

OK，最后一点说明：你的模型其实只是一个步长的，也就是说，知道 $x(k)$ ，我可以求 $x(k+1)$ 。问题是 $x(k)$ 是多少呢？答案： $x(k)$ 就是你上一步卡尔曼滤波得到的、所谓加权平均之后的那个、对 x 在 k 时刻的最佳估计值。

于是**迭代**也有了。

这就是卡尔曼滤波。

（无公式）

作者：Kent Zeng

链接：<https://www.zhihu.com/question/23971601/answer/26254459>

来源：知乎


著作权归作者所有。商业转载请联系作者获得授权，非商业转载请注明出处。

1. 滤波器作用

滤波器作用

滤波器的本质：结合预测与观测，得到最“精确”的后验值。

实际中，预测与观测均从传感器而来，因此滤波器的作用便是结合各传感器得到一个最好的融合结果。



- 1) 实际中预测往往从IMU、编码器传感器递推而来；
- 2) 观测往往从GPS、雷达、相机等传感器而来；
- 3) 后验为融合后的结果，即定位模块的输出。

融合直观的解释：

点云匹配：观测，波动比较大

IMU：比较稳定，可以作为预测，但是有累积误差

可以使用点云匹配的结果对IMU进行修正


最后得到一个没有累积误差而且波动比较小的结果。

2. 概率基础知识

2.1 概率、概率密度

概率基础知识

1. 概率、概率密度



上图中， $p(x)$ 为 x 在区间 $[a, b]$ 上的概率密度，它表示的是随机变量在区间的分布情况。

Pr 代表的是 x 在区间 $[c, d]$ 上的概率，它是概率密度的积分，

$$Pr(c \leq x \leq d) = \int_c^d p(x) dx$$

我们平时所说“高斯分布”、“非高斯分布”均是指它的概率密度。

概率密度直观上就是概率的形状，表示在区间的分布情况，上图中，一个值落在 $[a, b]$ 的概率是100%，但是落在中间某两个值之间的概率就需要使用概率密度函数来计算；

2.2 联合概率与条件概率

2. 联合概率

$x \in [a, b]$ 和 $y \in [r, s]$ 的联合概率密度函数可以表示为 $p(x, y)$ ，其积分表示 x 和 y 同时处在某个区间的概率，满足下式：

$$\int_a^b \int_r^s p(x, y) dy dx = 1$$

$= p(x)$

特别地，当 x 和 y 统计独立的时候，有

$$p(x, y) = p(x)p(y)$$

3. 条件概率

x 关于 y 的条件概率密度函数可以表示为

$$p(x | y)$$

其含义是，在 $y \in [r, s]$ 的前提下， $x \in [a, b]$ 的概率分布，并且满足下式

$$p(x) = \int_r^s p(x | y)p(y)dy$$

特别地，当 x 和 y 统计独立的时候，有

$$p(x | y) = p(x)$$

条件概率 $p(x|y)$ ：在 y 发生下 x 发生的概率

如果 x, y 统计独立，即 x, y 没有关系， y 对 x 没有影响，那么， $p(x|y)=p(x)$

如果 y 对 x 有影响， y 取任何一个值， x 都有一个概率 $p(x)$ ，为了得到完整的 $p(x)$ ，对 y 进行积分。

2.3 贝叶斯公式/推断

联合概率分解成条件概率和边缘概率的乘积，即

$$p(x, y) = p(x | y)p(y) = p(y | x)p(x)$$

重新整理，即可得贝叶斯公式

$$p(x | y) = \frac{p(y|x)p(x)}{p(y)}$$

贝叶斯推断可以理解为贝叶斯公式的运用，它是指，如果已知先验概率密度函数 $p(x)$ ，以及传感器模型 $p(y | x)$ ，那么就可以根据贝叶斯公式推断出后验概率密度。

$$p(x | y) = \frac{p(y|x)p(x)}{\int p(y|x)p(x)dx}$$

实际中，贝叶斯推断有时也叫贝叶斯估计。

贝叶斯估计具有**非常重大的意义**：

已知状态先验->可以推断出后验概率，也就是状态估计

比如说：

以下雨为一个状态 x ，当下雨时有乌云 y 的概率为先验 $p(y|x)$ ，使用贝叶斯公式可以得到 $p(x|y)$ ，即，当有乌云时，会下雨的概率，这就是对状态 x 的估计。

2.4 高斯概率密度函数

2.4.1 高斯概率密度函数



概率基础知识

6. 高斯概率密度函数

一维情况下，高斯概率密度函数表示为：

$$p(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2}\right)$$

其中 μ 为均值， σ^2 为方差。

多维情况下，高斯概率密度函数表示为

$$p(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{\sqrt{(2\pi)^N \det \boldsymbol{\Sigma}}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

向量 矩阵

其中均值为 $\boldsymbol{\mu}$ ，方差为 $\boldsymbol{\Sigma}$ 。

一般把高斯分布写成 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。

卡尔曼滤波以高斯概率函数为基础

2.4.2 联合高斯密度函数

若有高斯分布

$$p(\mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_{xx})$$

$$p(\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$$

则它们的联合概率密度函数可以表示为

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N}\left(\begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}\right)$$

由于联合概率满足下式

$$p(\mathbf{x}, \mathbf{y}) = p(\mathbf{x} | \mathbf{y})p(\mathbf{y})$$

该式在高斯分布的前提下可以重新分解。

由于高斯分布中指数项包含方差的求逆，而此处联合概率的方差是一个高维矩阵，对它求逆的简洁办法是运用舒尔补。

舒尔补的主要目的是把矩阵分解成上三角矩阵、对角阵、下三角矩阵乘积的形式，方便运算，即

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{D} & \mathbf{0} \\ \mathbf{0} & \mathbf{D} \end{bmatrix} \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ \mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix}$$

其中 $\Delta\mathbf{D} = \mathbf{A} - \mathbf{BD}^{-1}\mathbf{C}$ 称为矩阵D关于原矩阵的舒尔补。

此时有

$$\begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{C} & \mathbf{D} \end{bmatrix}^{-1} \text{ 方便求逆} = \begin{bmatrix} \mathbf{I} & \mathbf{0} \\ -\mathbf{D}^{-1}\mathbf{C} & \mathbf{I} \end{bmatrix} \begin{bmatrix} \Delta\mathbf{D}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{D}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{I} & -\mathbf{BD}^{-1} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}$$

利用舒尔补，联合分布的方差矩阵可以写为

$$\begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} = \begin{bmatrix} \mathbf{1} & \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1} \\ \mathbf{0} & \mathbf{1} \end{bmatrix} \begin{bmatrix} \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1}\boldsymbol{\Sigma}_{yx} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ \boldsymbol{\Sigma}_{yy}^{-1}\boldsymbol{\Sigma}_{yx} & \mathbf{1} \end{bmatrix}$$

它的逆矩阵为

$$\begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}^{-1} = \begin{bmatrix} \mathbf{1} & \mathbf{0} \\ -\boldsymbol{\Sigma}_{yy}^{-1}\boldsymbol{\Sigma}_{yx} & \mathbf{1} \end{bmatrix} \begin{bmatrix} (\boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1}\boldsymbol{\Sigma}_{yx})^{-1} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_{yy}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{1} & -\boldsymbol{\Sigma}_{xy}\boldsymbol{\Sigma}_{yy}^{-1} \\ \mathbf{0} & \mathbf{1} \end{bmatrix}$$

联合分布 $p(\mathbf{x}, \mathbf{y})$ 仍为高斯分布,

$$p(\mathbf{x}, \mathbf{y}) = \mathcal{N} \left(\begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix} \right)$$

它的指数部分的二次项包含如下内容

$$\begin{aligned} & \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right)^T \begin{bmatrix} \boldsymbol{\Sigma}_{xx} & \boldsymbol{\Sigma}_{xy} \\ \boldsymbol{\Sigma}_{yx} & \boldsymbol{\Sigma}_{yy} \end{bmatrix}^{-1} \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right) \\ &= \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right)^T \begin{bmatrix} 1 & 0 \\ -\boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx} & 1 \end{bmatrix} \begin{bmatrix} (\boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})^{-1} & 0 \\ 0 & \boldsymbol{\Sigma}_{yy}^{-1} \end{bmatrix} \begin{bmatrix} 1 & -\boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \\ 0 & 1 \end{bmatrix} \left(\begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} - \begin{bmatrix} \boldsymbol{\mu}_x \\ \boldsymbol{\mu}_y \end{bmatrix} \right) \\ &= \underbrace{\left(\mathbf{x} - \boldsymbol{\mu}_x - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y) \right)^T (\boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})^{-1} (\mathbf{x} - \boldsymbol{\mu}_x - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y))}_{\text{二次项}} \\ & \quad + \underbrace{(\mathbf{y} - \boldsymbol{\mu}_y)^T \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y)}_{\text{二次项}} \end{aligned}$$

最后得到两个二次项的和, 由于同底数幂相乘后, 底数不变, 指数相加, 且 $p(\mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_{yy})$

因此有 $p(\mathbf{x} | \mathbf{y}) = \mathcal{N}(\boldsymbol{\mu}_x + \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} (\mathbf{y} - \boldsymbol{\mu}_y), \boldsymbol{\Sigma}_{xx} - \boldsymbol{\Sigma}_{xy} \boldsymbol{\Sigma}_{yy}^{-1} \boldsymbol{\Sigma}_{yx})$

(包括以后) 最终目的就是为了获得 $p(\mathbf{x} | \mathbf{y})$

2.4.3 高斯随机变量的线性分布

在上面的例子中, 若已知 \mathbf{x} 和 \mathbf{y} 之间有如下关系

$$\mathbf{y} = \mathbf{G}\mathbf{x} + \mathbf{n}$$

其中 \mathbf{G} 是一个常量矩阵, $\mathbf{n} \sim \mathcal{N}(0, \mathbf{R})$ 为零均值白噪声, 在实际中指的是观测噪声。则 \mathbf{x} 和 \mathbf{y} 的均值和方差之间必然存在联系, 其联系可通过以下推导获得。

均值

$$\begin{aligned} \boldsymbol{\mu}_y &= E[\mathbf{y}] \\ &= E[\mathbf{G}\mathbf{x} + \mathbf{n}] \\ &= \mathbf{G}E[\mathbf{x}] + E[\mathbf{n}] \\ &= \mathbf{G}\boldsymbol{\mu}_x \end{aligned}$$

方差

$$\begin{aligned} \boldsymbol{\Sigma}_{yy} &= \boldsymbol{\Sigma}(\mathbf{G}\mathbf{x} + \mathbf{n}) \\ &= E[(\mathbf{G}\mathbf{x} - \boldsymbol{\mu}_y)(\mathbf{G}\mathbf{x} - \boldsymbol{\mu}_y)^T] + \mathbf{R} \\ &= \mathbf{G}E[(\mathbf{x} - \boldsymbol{\mu}_x)(\mathbf{x} - \boldsymbol{\mu}_x)^T] \mathbf{G}^T + \mathbf{R} \\ &= \mathbf{G}\boldsymbol{\Sigma}_{xx} \mathbf{G}^T + \mathbf{R} \end{aligned}$$

方差的交叉项

$$\begin{aligned} \boldsymbol{\Sigma}_{xy} &= E[(\mathbf{x} - \boldsymbol{\mu}_x)(\mathbf{y} - \boldsymbol{\mu}_y)^T] \\ &= E[(\mathbf{x} - \boldsymbol{\mu}_x)(\mathbf{G}\mathbf{x} - \mathbf{G}\boldsymbol{\mu}_x + \mathbf{n})^T] \\ &= E[(\mathbf{x} - \boldsymbol{\mu}_x)(\mathbf{G}\mathbf{x} - \mathbf{G}\boldsymbol{\mu}_x)^T + (\mathbf{x} - \boldsymbol{\mu}_x)\mathbf{n}^T] \\ &= \boldsymbol{\Sigma}_{xx} \mathbf{G}^T + E[(\mathbf{x} - \boldsymbol{\mu}_x)\mathbf{n}^T] \\ &= \boldsymbol{\Sigma}_{xx} \mathbf{G}^T \end{aligned}$$

同理可得 $\boldsymbol{\Sigma}_{yx} = \boldsymbol{\Sigma}_{xy}^T = \mathbf{G}\boldsymbol{\Sigma}_{xx}$

3. 滤波器基本原理

3.1 状态估计模型

1. 状态估计模型

实际状态估计任务中, 待估计的后验概率密度可以表示为:

$$p(\mathbf{x}_k | \tilde{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k})$$

其中

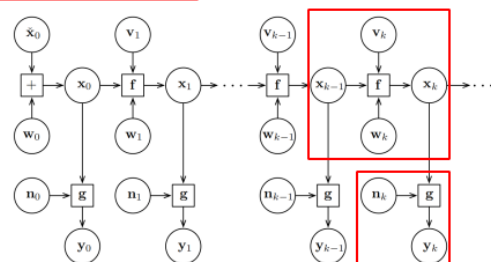
$\tilde{\mathbf{x}}_0$ 表示的是状态初始值

$\mathbf{v}_{1:k}$ 表示从1到k时刻的输入

$\mathbf{y}_{0:k}$ 表示从0到k时刻的观测

因此, 滤波问题可以直观表示为, 根据所有历史数据(输入、观测、初始状态), 得出最终的融合结果。

历史数据之间的关系, 可以用下面的图模型表示,



图模型中体现了马尔可夫性, 即当前状态只跟前一时状态相关, 和其他历史时刻状态无关。数学表达该性质,

$$\text{运动方程: } \mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{v}_k, \mathbf{w}_k)$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{g}(\mathbf{x}_k, \mathbf{n}_k)$$

3.2 贝叶斯滤波

2. 贝叶斯滤波

$$p(x|y) = \frac{p(y|x)p(x)}{p(y)}$$

根据贝叶斯公式， k 时刻后验概率密度可以表示为

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k}) = \frac{p(y_k | x_k, \tilde{x}_0, v_{1:k}, y_{0:k-1}) p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})}{p(y_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})}$$

$$= \eta p(y_k | x_k, \tilde{x}_0, v_{1:k}, y_{0:k-1}) p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

与 x_k 无关

根据观测方程， y_k 只和 x_k 相关，因此上式可以简写为

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k}) = \eta p(y_k | x_k) p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

应用系统的马尔可夫性进一步化简公式，

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

$$= \int p(x_k, x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

$$= \int p(x_k | x_{k-1}, \tilde{x}_0, v_{1:k}, y_{0:k-1}) p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

$$= \int p(x_k | x_{k-1}, v_k) p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

马尔可夫性：当前状态 x_k 只和前一时刻 x_{k-1} 有关

$$p(x) = \int p(x|y)p(y)dy \quad (1)$$

利用(1)可以让任意其他变量 y 与 x 发生关系，将 y 变成 x_{k-1} ， x_k 就和 x_{k-1} 发生了关联。

根据观测方程， y_k 只和 x_k 相关，因此上式可以简写为

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k}) = \eta p(y_k | x_k) p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

应用系统的马尔可夫性进一步化简公式，

$$p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k-1})$$

$$= \int p(x_k, x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

$$= \int p(x_k | x_{k-1}, \tilde{x}_0, v_{1:k}, y_{0:k-1}) p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

$$= \int p(x_k | x_{k-1}, v_k) p(x_{k-1} | \tilde{x}_0, v_{1:k}, y_{0:k-1}) dx_{k-1}$$

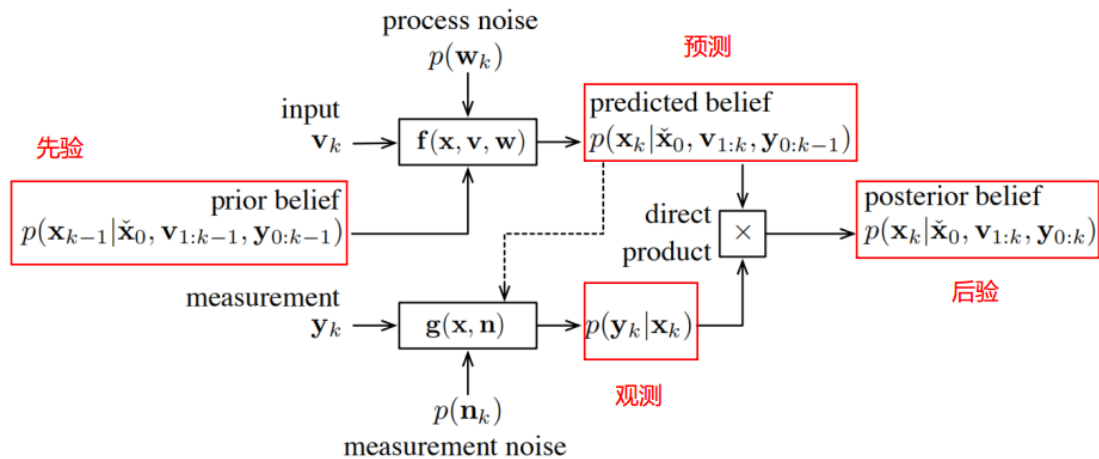
经过以上化简，最终后验概率可以写为

$$\underbrace{p(x_k | \tilde{x}_0, v_{1:k}, y_{0:k})}_{\text{estimate}}$$

$$= \eta \underbrace{p(y_k | x_k)}_{g(\cdot)} \int \underbrace{p(x_k | x_{k-1}, v_k)}_{f(\cdot)} \underbrace{p(x_{k-1} | \tilde{x}_0, v_{1:k-1}, y_{0:k-1})}_{\text{last estimate}} dx_{k-1}$$

观测
预测
先验

根据以上结果，可以画出贝叶斯滤波的信息流图如下

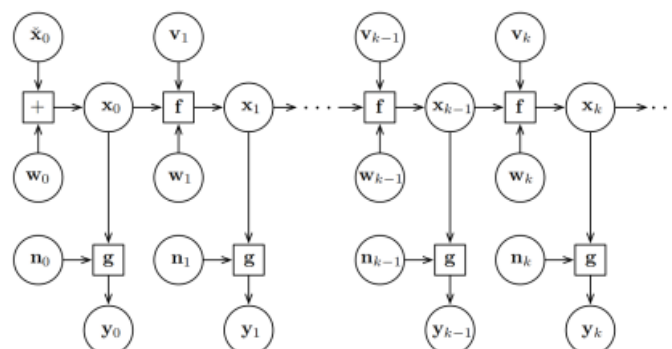


1) 在高斯假设前提下，用贝叶斯滤波的原始形式比较复杂，可以利用高斯的特征得到简化形式，即广义高斯滤波，后面KF、EKF、IEKF、UKF的推导均采用这种形式，只有PF例外，因为它是针对非高斯的。

2) 实际中，粒子滤波多用于(早期的)2D激光SLAM方案中，不属于本门课程讲解重点，因此只做原理介绍。

3.3 卡尔曼滤波(KF)推导

历史数据之间的关系，可以用下面的图模型表示，



图模型中体现了马尔可夫性，即当前状态只跟前一时状态相关，和其他历史时刻状态无关。数学表达该性质，

$$\text{运动方程: } x_k = f(x_{k-1}, v_k, w_k)$$

$$\text{观测方程: } y_k = g(x_k, n_k)$$

在线性高斯假设下，上式可以重新写为下面的形式(为了和后面符号对应)

$$\text{运动方程: } \mathbf{x}_k = \mathbf{F}(\mathbf{x}_{k-1}, \mathbf{v}_k) + \mathbf{B}_{k-1} \mathbf{w}_k$$

$$\text{观测方程: } \mathbf{y}_k = \mathbf{G}(\mathbf{x}_k) + \mathbf{C}_k \mathbf{n}_k$$

把上一时刻的后验状态写为

$$p(\mathbf{x}_{k-1} \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k-1}, \mathbf{y}_{0:k-1}) = \mathcal{N}(\hat{\mathbf{x}}_{k-1}, \hat{\mathbf{P}}_{k-1})$$

则当前时刻的预测值为

$$\check{\mathbf{x}}_k = \mathbf{F}(\hat{\mathbf{x}}_{k-1}, \mathbf{v}_k)$$

根据高斯分布的线性变化，它的方差为

$$\check{\mathbf{P}}_k = \mathbf{F}_{k-1} \hat{\mathbf{P}}_{k-1} \mathbf{F}_{k-1}^T + \mathbf{B}_{k-1} \mathbf{Q}_k \mathbf{B}_{k-1}^T$$

其中 \mathbf{Q}_k 为当前输入噪声的方差。

线性假设下:

运动方程:

$$x_k = f(x_{k-1}, u_k) + \varepsilon_k = A_k x_{k-1} + B_k u_k + \varepsilon_k$$

观测方程:

$$z_k = h(x_k) + \delta_k = C_k x_k + \delta_k$$

若把 k 时刻状态和观测的联合高斯分布写为

$$p(\mathbf{x}_k, \mathbf{y}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k-1}) = \mathcal{N}\left(\begin{bmatrix} \boldsymbol{\mu}_{x,k} \\ \boldsymbol{\mu}_{y,k} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{xx,k} & \boldsymbol{\Sigma}_{xy,k} \\ \boldsymbol{\Sigma}_{yx,k} & \boldsymbol{\Sigma}_{yy,k} \end{bmatrix}\right)$$

根据第1节7)中的推导结果， k 时刻的后验概率可以写为

$$\begin{aligned} p(\mathbf{x}_k \mid \check{\mathbf{x}}_0, \mathbf{v}_{1:k}, \mathbf{y}_{0:k}) \\ = \mathcal{N}(\underbrace{\boldsymbol{\mu}_{x,k} + \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} (\mathbf{y}_k - \boldsymbol{\mu}_{y,k})}_{\hat{\mathbf{x}}_k}, \underbrace{\boldsymbol{\Sigma}_{xx,k} - \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1} \boldsymbol{\Sigma}_{yx,k}}_{\hat{\mathbf{P}}_k}) \end{aligned}$$

其中 $\hat{\mathbf{x}}_k$ 和 $\hat{\mathbf{P}}_k$ 分别为后验均值和方差。若定义

$$\mathbf{K}_k = \boldsymbol{\Sigma}_{xy,k} \boldsymbol{\Sigma}_{yy,k}^{-1}$$

则有

$$\begin{aligned} \hat{\mathbf{P}}_k &= \check{\mathbf{P}}_k - \mathbf{K}_k \boldsymbol{\Sigma}_{xy,k}^T \\ \hat{\mathbf{x}}_k &= \check{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - \boldsymbol{\mu}_{y,k}) \end{aligned}$$

把第1节8)中的推导得出的线性变换后的均值、方差及交叉项带入上面的式子，可以得到：

$$K_k = \check{P}_k G_k^T (G_k \check{P}_k G_k^T + C_k R_k C_k^T)^{-1}$$

$$\hat{P}_k = (1 - K_k G_k) \check{P}_k$$

$$\hat{x}_k = \check{x}_k + K_k (y_k - G(\check{x}_k))$$

上面方程与之前所述预测方程(如下)，就构成了卡尔曼经典五个方程。

$$\check{x}_k = F(\hat{x}_{k-1}, v_k)$$

$$\check{P}_k = F_{k-1} \hat{P}_{k-1} F_{k-1}^T + B_{k-1} Q_k B_{k-1}^T$$

需要说明的是，若不把第1节8)中的结果带入，而保留上页的原始形式，则对应的五个方程被称为广义高斯滤波。

.....

- 1) 相比于推导方法，理解它的本质更重要，即“信息加权”和“权重调节”；
- 2) 滤波器还有其他很多种推导方式，只需理解它的一种推导方法即可，不要做“孔乙己”；
- 3) 实际工程中，滤波器的表现受多种因素的影响，现象千变万化，脱离工程不可能深入理解滤波器。
- 4) 在2D激光SLAM中，随着基于优化方案的优势越来越明显，基于PF的方法逐渐“过时”（尽管很多人并不赞同这一点）。

我认为不需要掌握卡尔曼滤波器的具体数学推导,只需要记住卡尔曼滤波的五个方程,理解物理意义,根据实际要求使用KF.

```

Algorithm Kalman_filter( $\mu_{k-1}, \Sigma_{k-1}, u_k, z_k$ ):
  for all  $x_k$  do
     $\bar{\mu}_k = A_k \mu_{k-1} + B_k u_k$ 
     $\bar{\Sigma}_k = A_k \Sigma_{k-1} A_k^T + R_k$ 

     $K_k = \bar{\Sigma}_k C_k^T (C_k \bar{\Sigma}_k C_k^T + Q_k)^{-1}$ 
     $\mu_k = \bar{\mu}_k + K_k (z_k - C_k \bar{\mu}_k)$ 
     $\Sigma_k = (I - K_k C_k) \bar{\Sigma}_k$ 
  end for
  return  $\mu_k, \Sigma_k$ 
  
```

Algorithm Bayes_filter($bel(\mathbf{x}_{k-1}), u_k, z_k$):

for all x_k do

$$\bar{bel}(\mathbf{x}_k) = \int p(\mathbf{x}_k | \mathbf{x}_{k-1}, u_k) bel(\mathbf{x}_{k-1}) d\mathbf{x}_{k-1}$$

$$bel(\mathbf{x}_k) = \eta p(z_k | \mathbf{x}_k) \bar{bel}(\mathbf{x}_k)$$

end for

return $bel(\mathbf{x}_k)$

Algorithm Kalman_filter($\mu_{k-1}, \Sigma_{k-1}, u_k, z_k$):

for all x_k do

$$\bar{\mu}_k = A_k \mu_{k-1} + B_k u_k$$

$$\bar{\Sigma}_k = A_k \Sigma_{k-1} A_k^T + R_k$$

$$K_k = \bar{\Sigma}_k C_k^T (C_k \bar{\Sigma}_k C_k^T + Q_k)^{-1}$$

$$\mu_k = \bar{\mu}_k + K_k (z_k - C_k \bar{\mu}_k)$$

$$\Sigma_k = (I - K_k C_k) \bar{\Sigma}_k$$

end for

return μ_k, Σ_k

预测

测量更新

信息加权,权重调节:

卡尔曼滤波核心思想是将预测的状态和观测的状态进行加权融合,权重调节由卡尔曼增益K控制;

预测噪声方差R

观测噪声方差Q

谁越小,就越相信谁,体现在K: